

指标评测总说明（通俗版，优先审阅）

你之前反馈“文档太复杂、看不懂”。这份文件按你的要求重写为一个大MD：

>>> 先给“阶段→维度→指标”的总表（结构对齐 docs/评测指标目前设想.md，不丢指标）

>>> 再逐指标写清：用哪个 Excel / sheet / 列、怎么算（公式/提示词）、需要哪些上下文、如何导出可复核的 source data

>>> 不再使用“canonical”等术语；统一叫：检查匹配重建表 / 合理性标注表 / 信息增益标注表等

0) 已拍板口径（执行与报告统一按此）

主题	口径
D1 决策异常输出 (D1 出现“修正诊断/治疗方案”，但缺“初步诊断/建议检查”)	D1 计失败；同时按 D2 指标体系照常评分并纳入 D2 统计，并标记 <code>is_anomaly_d1_to_d2=true</code>
检查匹配率(严格)	分母=AI“请求检查数”；分子=“已执行且与GT检查语义匹配”的数量（优先复用 judge 的匹配结果/计数，不做字符 exact match）
检查合理性匹配率(扩展，待实现)	分母=AI“请求检查数”；分子=匹配数 + 未匹配但仍有临床意义且非冗余的数量（需 LLM 标注；当前先以 strict 指标产出并做可追溯审阅）
继承度（重复开单）	两个方向都输出：重复率(越低越好) 与 非重复比例(越高越好)=1-重复率
无效循环率	优先复用现有 judge 每轮字段：第 <i>i</i> 轮_判官_原始JSON_匹配数量 / 总请求数量 / 评分_检查匹配度（并输出逐轮 source data 便于人工复核）；但计数时以“AI真实提项”为基准做检查匹配重建（保留 raw judge 值对照）
Top-k 诊断覆盖率	只评 D1 初步诊断；k 固定 {1,3,5}
鉴别诊断	仅武汉存在，格式统一：初步诊断:... + 鉴别诊断:...；按模板算法拆分为结构化列表再做多对多语义匹配

1) 数据源速查（只读 data/ 与 docs/；不改原始 Excel）

类型	路径模式	Sheet	主键	说明
GT (真值)	data/<中心>/GT/standardized_*.xlsx	Sheet1	CaseID	病历事实、GT检查/诊断/方案文本（用于对照与 LLM 上下文）

类型	路径模式	Sheet	主键	说明
doc (医生输出)	data/<中心>/doc agent/Evaluation_Summary_<model>_CN_Parsed.xlsx	6张固定：D1_Outpatient_Loop / D1_Outpatient_Decision / D2_Admission_Loop / D2_Admission_Decision / D3_Surgery_Decision / D4_Rehab_Plan	病例ID	AI 医生输出（已抽取列；不同模型可能缺列但不应阻塞）
judge (裁判输出)	data/<中心>/judge agent/Evaluation_Summary_<model>_CN_Judge_Parsed.xlsx	同上 6 张	病例ID	Gate 判定、匹配结果、评分、二审结果等（部分可直接复用）

Join key: GT 用 CaseID；doc/judge 用 病例ID；内容上对应同一 case（如 foshan_3）。

2) 最容易搞错的字段归属（D1 / D2 的“检查”到底属于谁？）

你已指出并确认：D1_Outpatient_Decision 的 医生决策_原始JSON_建议检查项目 实际是“入院检查/术前检查建议”，应归入 D2 的检查指标；Gate1 judge 的“检查匹配”也是在匹配这些入院检查。

阶段	doc: AI输出列（输入）	judge: 裁判列（可复用）	GT参考字段	归属说明
D1 门诊补充检查 (Loop)	D1_Outpatient_Loop: 第i轮_医生_原始JSON_诊断前所需检查 (优先) + 第i轮_医生_原始JSON_需要补充门诊检查 (若存在) + 第i轮_医生_原始JSON_理由	D1_Outpatient_Loop: 第i轮_判官_原始JSON_匹配的检查项目 / AI建议但实际未执行的检查 / 匹配数量 / 总请求数量 / 评分_检查匹配度 / 评分_合理性评分 / reason	GT_Outpatient_Checks	门诊检查类指标输入
D1 门诊决策 (Decision)	D1_Outpatient_Decision: 医生决策_原始JSON_初步诊断列表 / 初步诊断思维 / 门诊信息汇总 / 诊断置信度	D1_Outpatient_Decision: Gate1...诊断匹配_结论/评分 / 是否继续评测	GT_Admission_Diagnosis (按口径)	D1 诊断/Gate1 指标
D2 入院补充检查 (Loop+来自D1建议)	D1 决策 医生决策_原始JSON_建议检查项目 + D2_Admission_Loop: 第i轮_医生_原始JSON_需要补充检查	Gate1 检查匹配: D1_Outpatient_Decision: Gate1判官_原始JSON_检查匹配_* + D2_Admission_Loop 每轮判官匹配字段	GT_Admission_Checks (特殊情形见下)	入院检查类指标输入 (含D1 建议入院检查)
D2 入院决策 (Decision)	D2_Admission_Decision: 医生决策_原始JSON_修正诊断 / 初步治疗方案 / 治疗方案思维 / 置信度	D2_Admission_Decision: Gate2...修正诊断匹配_评分 / 手术方案匹配_评分 / 二审 is_reasonable	GT_Revised_Diagnosis / GT_Surgery_Plan 等	D2 指标
D3 术后决策 (Decision)	D3_Surgery_Decision: 医生_原始JSON_最终诊断_诊断名称 / 术后治疗方案_方案详情	D3_Surgery_Decision: 判官...诊断匹配评估_评分 / 治疗方案匹配评估_评分	GT_Final_Diagnosis / GT_PostOp_Plan	D3 指标
D4 康复/随访 (Decision)	D4_Rehab_Plan: 出院康复计划_方案详情 / 长期随访计划_方案详情	D4_Rehab_Plan: 判官...康复计划评估_评分 / 随访计划评估_评分	GT_Rehab_Plan / GT_Followup_Plan	D4 指标

特殊情形：AI 未经过 D1 loop

当 `D1_Outpatient_Loop.状态 = 未经过` 时，现实中可能出现：**D1 decision 与 D2 loop 同时对“AI要求的检查”与“实际门诊+入院检查”做匹配**。为避免混乱：

- >>> D1 门诊检查指标：该 case 直接记为 **Not_Evaluated（未评测）**（不当失败）
- >>> D2 入院检查指标：GT 参考集合使用 `GT_Outpatient_Checks ∪ GT_Admission_Checks`（因为匹配对象实际包含门诊+入院检查）

3) “检查匹配重建”规则（解决 judge 输出里出现“AI没提但被算进匹配”的问题）

你给的典型例子（必须处理）：

- >>> `foshan_16`：judge 匹配的检查项目 里出现 血常规，但 AI 并未请求 → **必须忽略该项**，不能让它影响 AI 的匹配计数与 precision/无效循环率等
- >>> `foshan_3`：judge 列表只给了 妇科超声，reason 说明 经阴道超声 ↔ 彩超 的语义匹配 → 需要能从 reason/列表重建出“AI提项→匹配到的实际检查”的对应关系

核心原则：一切计数以 AI 真正提出的检查项为主键。 judge 的“匹配的检查项目/内容”只作为对齐证据，不允许反向把“实际执行检查”混进 AI 请求集合。

重建输入（Excel列）

- >>> AI 请求检查 (doc)：第*i*轮_医生_原始JSON_诊断前所需检查 / 需要补充门诊检查 / 需要补充检查 / 医生决策_原始JSON_建议检查项目
- >>> judge 匹配与解释：第*i*轮_判官_原始JSON_匹配的检查项目 / AI建议但实际未执行的检查 / reason / 匹配数量 / 总请求数量

重建输出（结构化表）

- >>> 对每条 `ai_check_item` 输出：`matched(boolean)`、`matched_to`（匹配到的实际检查/泛化类别）、`evidence`（引用到 judge reason 或匹配列表）
- >>> 同时输出：`judge_extra_matched_not_requested[]`（用于审计，不参与计数）

冲突处理策略

- 1 优先使用结构化列：`匹配的检查项目 / AI建议但实际未执行的检查`
- 2 若结构化列不足以定位（如只给泛化项），再用 `reason` 做补充抽取
- 3 仍无法重建：

>>> 数量少 → 产出“人工复核清单”（human-in-loop）

>>> 数量多 → 触发 LLM 重判，生成同结构输出（输入仍只取 Excel 列值）

4) 指标总表 (与 docs/评测指标目前设想.md 对齐)

4.1 算法指标 (含 LLM 辅助算法指标)

说明：这里的“算法”指**最终计算是公式/统计**，但很多分子分母来自 judge 或补评 LLM 的语义结果（你已明确：禁止纯字符串 exact match）。

指标ID	指标名	阶段	公式/定义 (字段名不省略)
alg.check.recall	检查召回率	D1/D2 检查	$\text{matched_gt_effective_count} / \text{gt_effective_total_count}$ (匹配重建后计数)
alg.check.precision	检查精确率	D1/D2 检查	$(\text{matched_ai_count} + \text{reasonable_unmatched_ai_count}) / \text{ai_total_requested_count}$
alg.check.f1	检查 F1	D1/D2 检查	$2 * P * R / (P + R)$
alg.loop.inefficiency	无效循环率	D1/D2 Loop	$\text{inefficient_rounds} / \text{executed_rounds}$ (逐轮定义见 5.1)
alg.loop.efficiency	循环效率	D1/D2 Loop	$\text{avg}(\text{executed_rounds})$ (数值越低越好)
alg.gate.pass_rate	Gate 通过率	D1/D2/D3	$\text{passed_cases} / \text{evaluated_cases}$ (Not_Evaluated 不计失败)
alg.gate.status_distribution	Gate 状态分布	D1/D2/D3	统计 Passed / Secondary_Override / Failed / Not_Evaluated / Anomaly
alg.dx.topk_coverage	Top-k 诊断覆盖率	D1	语义命中: hit@k (k={1,3,5}; many-to-many; 含鉴别诊断拆分)
alg.info.duplication_rate	重复率 (继承度)	D2	$\text{dup_count} / \text{d2_requested_total}$ (D2 请求与 D1 已获有效检查语义重复的比例)
alg.info.non_dup_ratio	非重复比例	D2	$1 - \text{duplication_rate}$
alg.error.cascade_prob	错误级联传导率	全流程	$P(\text{Dn+1失败} \mid \text{Dn存在偏差})$ (偏差来自 LLM“级联风险分析”，见 5.4)

指标ID	指标名	阶段	公式/定义（字段名不省略）
不知道取名	错误分析	全流程	由于某一轮结束了后面就不再进行，因此我觉得应该是由一个judge来分析，虽然AI这一步答对了，但是存在哪些地方他没有做好：信息漏了（检查），对疾病的判断和真实情况存在较大偏差（和GT或者是和指南）等情况，然后这种偏差会导致下一步失败，或者导致虽然整个过程都答对了，但是仍然存在风险 可以修缮一下这个想法，我觉得比较朴素，
alg.calibration.ece	置信度校准 (ECE)	多阶段	用 doc 的置信度列 + 对应阶段正确性标签（来自 gate/LLM）计算


4.2 LLM as Judge 指标汇总（阶段→维度→指标）

诊疗阶段	评测维度	指标（同一维度下可多项）
门诊-补充检查 (D1 Loop)	检查质量	必要性 / 冗余度 / 成本效益比
门诊-补充检查 (D1 Loop)	推理质量	推理证据链质量（观察-推断-结论）
门诊-补充检查 (D1 Loop)	记忆与稳定性	事实一致性（含幻觉） / 重要信息丢失
门诊-决策1 (D1 Decision)	记忆与稳定性	事实一致性（含幻觉） / 重要信息丢失 / 历史信息利用率
门诊-决策1 (D1 Decision)	诊断质量	Top-k语义命中 / 诊断准确性 / 合理性 / 逻辑性
住院-补充检查 (D2 Loop + D1建议入院检查)	推理质量	推理证据链质量（含D1建议入院检查的理由）
住院-补充检查 (D2 Loop + D1建议入院检查)	记忆能力	历史信息继承度（门诊信息留存） / 事实一致性 / 重要信息丢失
住院-补充检查 (D2 Loop + D1建议入院检查)	检查质量	必要性 / 冗余度 / 成本效益比
住院-决策2 (D2 Decision)	诊断质量	修正诊断准确性 / 合理性 / 逻辑性
住院-决策2 (D2 Decision)	治疗质量	方案准确性 / 安全性 / 完备性 / 合理性（D2初步治疗方案）
住院-决策2 (D2 Decision)	记忆能力	历史信息继承度 / 事实一致性 / 重要信息丢失
术后-决策3 (D3 Decision)	诊断质量	最终诊断准确性（含分期分级） / 合理性 / 逻辑性
术后-决策3 (D3 Decision)	术后治疗	方案规范性/安全性/完备性/合理性（D3术后治疗方案）


诊疗阶段	评测维度	指标（同一维度下可多项）
术后-决策3（D3 Decision）	诊断偏向性	偏向方向（保守/激进/中立）+ 程度（0-5）
康复-决策4（D4 Decision）	康复规划	完整性 / 合理性（饮食/活动/伤口/并发症监测等）
康复-决策4（D4 Decision）	随访策略	合理性 / 覆盖性（频率/风险覆盖）

4.3 LLM指标输入/输出结构（Mermaid）


LLM-诊断TopK语义命中（D1）




LLM-诊断质量（D1/D2/D3）




LLM-未匹配检查合理性 (D1/D2)




LLM-推理证据链质量 (D1/D2/D3)




LLM-事实一致性与信息丢失 (D1/D2/D3/D4)




LLM-方案质量 (D2/D3)



LLM-诊断偏向性 (D3)



LLM-康复/随访计划质量 (D4)



5) 逐指标实现说明 (Excel字段 + 公式/提示词 + Context pack)

5.1 D1/D2 检查类算法指标 (Recall/Precision/F1/无效循环率)

5.1.1 alg.check.recall

项	内容
评估粒度	case × stage（内部可按 round 先重建再汇总）
GT 分母字段	GT: <code>Sheet1.GT_Outpatient_Checks</code> (D1) / <code>Sheet1.GT_Admission_Checks</code> (D2; 若 D1 loop 未经过则用两者并集)
AI 请求字段	D1: <code>D1_Outpatient_Loop.第i轮_医生_原始JSON_诊断前所需检查</code> (优先) ± <code>需要补充门诊检查</code> ; D2: <code>D1_Outpatient_Decision.医生决策_原始JSON_建议检查项目</code> + <code>D2_Admission_Loop.第i轮_医生_原始JSON_需要补充检查</code>
匹配分子来源	judge 结构化列 (优先) + 必要时 reason/LLM补评 → 形成“检查匹配重建表”后计数
公式	<code>Recall = matched_gt_effective_count / gt_effective_total_count</code>
缺失/未经过	stage 未进入 → <code>Not_Evaluated</code> ; 不计入失败
Source data (导出给你复核)	每个 case 输出: <code>gt_effective_total_count</code> 、 <code>matched_gt_effective_count</code> 、以及逐条 <code>ai_check_item -> matched_to</code> (可在Excel展开或单独sheet)

5.1.2 `alg.check.precision` 与 `alg.check.f1`

项	内容
关键点	未匹配不一定“错”，需要 judge/LLM 判定其是否“在该病例下有意义” (<code>reasonable_unmatched_ai_count</code>)
公式	<code>Precision = (matched_ai_count + reasonable_unmatched_ai_count) / ai_total_requested_count</code> ; <code>F1 = 2PR/(P+R)</code>
需要的额外LLM输出	<code>llm.check.reasonable_unmatched_label</code> : 对每条未匹配 AI 检查输出 <code>{reasonable:0/1, reason}</code> (输入只取 Excel 列值)
Source data (导出给你复核)	每条 AI 检查输出: <code>matched?</code> 、 <code>reasonable?</code> 、证据; 并汇总到 <code>matched_ai_count/reasonable_unmatched_ai_count/ai_total_requested_count</code>

5.1.3 `alg.loop.inefficiency` (无效循环率)

你问“能不能直接用 judge 的 `评分_检查匹配度 / 匹配数量 / 总请求数量` 来测量？”——可以作为 v1 的逐轮可解释信号，但要注意：

- >>> `匹配数量/总请求数量` 有时会被“judge 自己提取的实际执行检查”污染 (如 `foshan_16`)，因此计数必须以“检查匹配重建表”为准
- >>> 我们会同时导出 **raw judge 值**与**重建后计数**，方便你一眼看出差异

v1 默认逐轮定义 (可在实现里配置阈值)：

- >>> `executed_round`：该轮 doc 请求字段非空

>>> inefficient_round: reconstructed_matched_ai_count == 0 且 judge:评分_合理性
评分 较低 (默认阈值 0.5, 可配)

Source data (逐轮表, 方便你自己在Excel算均值)

```
center, model, case_id, round_idx, doc_ai_requests_text,  
ai_total_requested_count, judge_matched_list_raw, judge_matched_count_raw,  
judge_total_requested_count_raw, judge_match_score_raw,  
judge_reasonable_score_raw, reconstructed_matched_ai_count,  
inefficient_round_flag
```

5.2 D1 诊断 Top-k (仅D1; 含武汉鉴别诊断)

5.2.1 alg.dx.topk_coverage

项	内容
GT 字段	GT:Sheet1.GT_Admission_Diagnosis (其中武汉可能含“初步诊断/鉴别诊断”模板文本)
AI 字段	doc:D1_Outpatient_Decision.医生决策_原始JSON_初步诊断列表 (若为文本列表, 需拆分成 top-k)
语义匹配	不做字符串匹配; 用 LLM 输出 {hit@1, hit@3, hit@5, matched_pairs[]} (many-to-many)
武汉鉴别诊断处理	先用规则拆出 primary_dx[] 与 differential_dx[]; 分别评估 (primary用于 Top-k主指标; differential可输出附加覆盖率/一致性)
Source data	导出 GT/AI 拆分后的列表 + LLM 输出的 matched_pairs, 保证你可人工核对

5.3 Gate / 终止 / 未评测 (避免把 Not_Evaluated 当失败)

项	内容
真值状态来源	以 doc Parsed 的 状态 为准 (每个 sheet 第2列)
不一致处理	judge 的 状态 与 Parsed 不一致: 仅在 work/<run_id>/fixed_excels/ 副本修正, 并输出审计清单
聚合分桶	Passed / Failed / Secondary_Override / Not_Evaluated / Anomaly
Source data	导出每个 case × stage 的 flow_status 与 gate 字段 (是否继续评测、匹配结论/评分、二审 is_reasonable)

5.4 错误级联（LLM偏差分析 + 算法条件概率）

你希望“即使后面都通过，也要分析前一步哪些没做好、会导致下一步风险”。因此我们把“偏差/风险”本身做成 LLM 指标，然后再算级联概率。

```
>>> LLM 输出（结构化）： llm.cascade_risk

>>> 输入：该阶段 AI 输出 + GT 事实/检查/诊断 + 该阶段 judge 结论（如有）

>>> 输出： {bias_tags[], missing_info[], risky_assumptions[],
            likely_next_stage_impact[], severity(0-5), evidence}

>>> 算法统计： P(Dn+1失败 | Dn存在偏差) （偏差=severity≥阈值）
```

6) LLM 指标的上下文（Context pack）怎么给：每个指标都写清“引用哪些列”

总原则：LLM 输入只取 Excel 已抽取列值（doc/judge/GT），不读取原始对话与未抽取JSON；上下文宁可“多一点”，也不要漏关键事实。

指标组	AI引用 (doc 列)	GT引用 (GT列)	judge引用 (judge列, 可 选)
检查质量 (必 要性/冗余/成 本)	D1/D2 loop 的 ...需要 补充... + 理由	D1 仅 GT_outpatient_checks; D2 用 GT_outpatient_checks + GT_admission_checks + 病历 事实字段	对应 loop 的 评 分_合理性评 分、 reason + D1已匹配检查 (用于冗余判 断)
事实一致性/信 息丢失	门诊信息 汇总 / 诊 疗经过回 顾 / 术后 信息汇总 / 康复阶 段信息汇 总	病历事实字段全量 (BasicInfo/ChiefComplaint/PresentIllness/...)	可选: gate 判 定理由
推理证据链质 量	该阶段 理由/思 维	关键事实字段 (可选)	可选: judge reason
诊断TopK (D1)	初步诊断 列表	GT_admission_diagnosis	可选: Gate1 诊 断匹配理由

指标组	AI引用 (doc 列)	GT引用 (GT列)	judge引用 (judge列, 可 选)
诊断质量 (D1/D2/D3)	D1: 初步 诊断列表/ 思维; D2: 修正 诊断/思 维; D3: 最终诊断 _诊断名 称/思维	D1: GT_Admission_Diagnosis; D2: GT_Revised_Diagnosis; D3: GT_Final_Diagnosis + 关 键事实/病理	可选: Gate1/Gate2 诊 断理由
诊断偏向性 (D3)	最终诊断 _诊断名 称	GT_Final_Diagnosis + 病理/手术信息	可选: judge reason
方案质量 (D2/D3)	初步治疗 方案/术后 治疗方案 + 方案思 维	GT_Surgery_Plan/GT_PostOp_Plan + 关键事实/病理	gate/判官的方 案评分与理由 (可选)

7) 你要的“可复核计算过程”：统一输出 metrics_source_data.xlsx

你明确说“最重要的是看到算指标的过程”，所以把 **source data** 作为一等产物：

- >>> 输出位置： `outputs/<run_id>/metrics_source_data.xlsx` （不写入 `data/` / `docs/`）
- >>> 结构建议（多 sheet，便于你透视表）：
 - >>> `case_index`： `center/model/case_id/flow_status_*` + gate关键字段
 - >>> `d1_loop_rounds`：逐轮请求/匹配/评分（含 raw judge 与重建后计数）
 - >>> `d2_loop_rounds`：同上
 - >>> `check_recall_precision_source`：每 case 的分子分母与展开明细入口
 - >>> `dx_topk_source`：GT/AI 列表 + 命中对
 - >>> `inheritance_source`：D1已获有效检查集合、D2请求集合、重复判定结果
 - >>> `calibration_source`：置信度列 + 正确性标签（可复核ECE）

Excel “更人类可读”的样式（你提到的表头/背景色/分组）将在生成器里实现：按主题给列分区、状态高亮、冻结首行、筛选器等；同时保留同名 CSV/JSONL 便于脚本复现。